# Análise Comparativa de Algoritmos de Machine Learning para Previsão de Criminalidade Violenta utilizando o Dataset Communities and Crime

Caio Varandas do Carmo
Pontifícia Universidade Católica de Goiás
Goiânia – 2026

***Resumo*—Este trabalho apresenta uma análise comparativa de métodos de classificação aplicados à base de dados *Communities and Crime*. Foram utilizados oito algoritmos de *Machine Learning*, incluindo Regressão Logística, Random Forest e Gradient Boosting, para prever a incidência de crimes violentos em um cenário de classificação binária. O estudo avaliou o impacto da técnica de redução de dimensionalidade (PCA) e a padronização via Z-score. Os resultados, obtidos por meio de validação cruzada com cinco *folds* e avaliação no conjunto de teste, indicam que os modelos treinados diretamente sobre os dados padronizados apresentaram desempenho superior às versões com redução de dimensionalidade. A Regressão Logística e o Gradient Boosting atingiram a maior acurácia (84,7%), com o Gradient Boosting apresentando vantagem na redução de falsos negativos ao classificar áreas de alto risco.**

## I. INTRODUÇÃO

De acordo com levantamentos globais conduzidos pelo Escritório das Nações Unidas sobre Drogas e Crime (United Nations Office on Drugs and Crime, 2019), a violência urbana constitui um dos problemas estruturais mais complexos enfrentados pela gestão pública contemporânea, impactando diretamente a qualidade de vida da população, a saúde coletiva e o desenvolvimento econômico das cidades. Estudos sociológicos indicam que a distribuição espacial da criminalidade não ocorre de forma aleatória, estando frequentemente associada a fatores socioeconômicos como desigualdade social, desemprego, densidade populacional e características da estrutura familiar. Essa interpretação é fortemente fundamentada na Teoria da Desorganização Social proposta por Shaw e McKay (1942).

Com o avanço da disponibilidade de bases de dados socioeconômicos em larga escala, técnicas de aprendizado de máquina passaram a ser utilizadas para identificar padrões complexos relacionados à criminalidade. Conforme demonstrado por McClendon e Meghanathan (2015), algoritmos supervisionados possuem capacidade significativa de capturar relações não lineares presentes em dados sociais.

Neste contexto, o objetivo deste trabalho consiste em comparar diferentes algoritmos de classificação supervisionada aplicados à previsão de criminalidade violenta utilizando o dataset *Communities and Crime*, disponibilizado pela UCI Machine Learning Repository e originalmente organizado por Redmond e Baveja (2002) (Repository, 1995). A motivação principal reside na possibilidade de fornecer ferramentas analíticas capazes de auxiliar gestores públicos na formulação de políticas de segurança e na alocação mais eficiente de recursos.

O restante do artigo está estruturado da seguinte maneira. A Seção II descreve os materiais e métodos empregados no estudo. A Seção III apresenta os resultados experimentais e a análise comparativa dos algoritmos. Por fim, a Seção IV apresenta as conclusões do trabalho.

## II. MATERIAIS E MÉTODOS

O estudo utilizou o dataset *Communities and Crime*, composto por 1994 instâncias e 128 atributos socioeconômicos e demográficos derivados do censo norte-americano e de registros policiais.

### A. Pré-processamento e Padronização

Durante a etapa inicial de análise exploratória observou-se a presença de dados faltantes em diversas variáveis. Para lidar com esse problema foi estabelecida uma regra de remoção de atributos com grande quantidade de ausência de dados. Todas as colunas que possuíam mais de 80% de valores faltantes foram descartadas. Essa análise revelou que 22 variáveis apresentavam aproximadamente 84% de valores ausentes, sendo majoritariamente relacionadas a dados administrativos de departamentos policiais locais.

Após a remoção dessas variáveis, os valores faltantes remanescentes nas demais características foram tratados por meio de imputação utilizando a média de cada atributo. Variáveis identificadoras que não contribuem para a modelagem preditiva também foram removidas.

Posteriormente os dados foram padronizados utilizando a técnica de normalização Z-score, uma etapa fundamental para garantir que todas as características contribuam equitativamente para o modelo, evitando distorções em algoritmos baseados em distância (como KNN e SVM) ou em variância (como o PCA). Este método transforma os dados originais ($x$) ao subtrair a média da característica ($\mu$) e dividir o resultado pelo seu desvio padrão ($\sigma$), resultando em variáveis com média zero e variância unitária:

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

### B. Análise de Correlação e Redução de Dimensionalidade

Devido ao extenso número de características, a visualização de uma matriz de correlação tradicional tornou-se inviável. Para diagnosticar a estrutura de multicolinearidade na fase exploratória, aplicou-se o agrupamento hierárquico (*Hierarchical Clustering*) utilizando o método *Ward* sobre a matriz de distâncias das correlações.

As variáveis foram divididas em 7 agrupamentos temáticos, revelando blocos densos de informações correlacionadas: Estrutura familiar e raça; Renda e nível socioeconômico; Imigração; Estrutura familiar e densidade domiciliar; Tamanho populacional; Estrutura etária; e Mercado de trabalho e urbanização. A Figura 1 ilustra os mapas de calor dessas correlações.

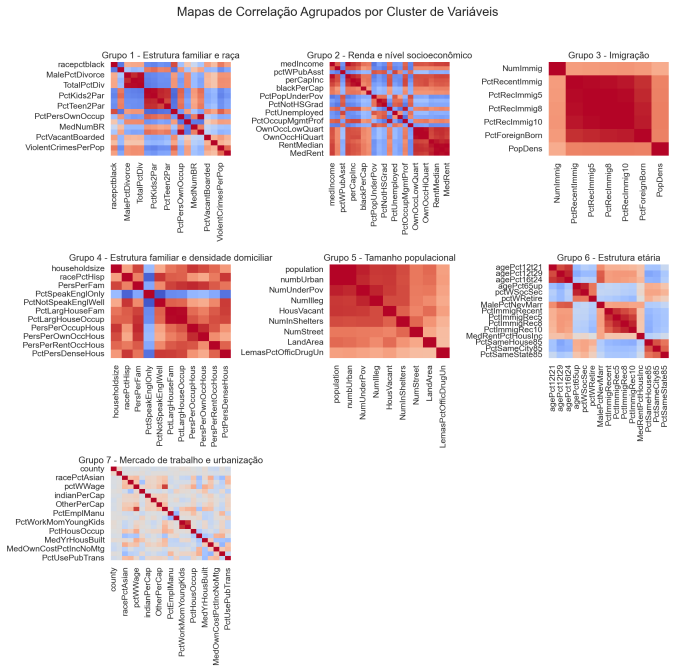


Figura 1. Mapas de Correlação agrupados por Cluster de Variáveis utilizando método de Ward.

A confirmação visual da forte presença de multicolinearidade embasou a necessidade teórica de aplicar técnicas de redução de dimensionalidade. Aplicou-se a Análise de Componentes Principais (PCA) sobre os previsores ($X$), parametrizada para reter 95% da variância explicada. Para fins de rigor comparativo, o desempenho dos classificadores foi testado em dois cenários distintos: utilizando os dados com PCA e utilizando o conjunto original padronizado (Sem PCA).

### C. Definição do Problema e Modelagem

A variável alvo *ViolentCrimesPerPop* é originalmente contínua. Para adequar o problema a uma tarefa de classificação, estabeleceu-se a mediana da distribuição como limiar de corte. Instâncias com taxas acima da mediana foram rotuladas como classe 1 (Alto Risco), enquanto as demais foram rotuladas como classe 0 (Baixo Risco).

O conjunto de dados foi particionado utilizando a proporção de 80% para treinamento e 20% para validação/teste. Foram implementados oito algoritmos utilizando a biblioteca *Scikit-Learn* (Pedregosa *et al.*, 2011). Para garantir uma comparação justa, optou-se por utilizar os hiperparâmetros padrão da biblioteca, realizando ajustes mínimos apenas quando necessário para garantir a convergência. A Tabela I sumariza as configurações.

Tabela I
PARÂMETROS DOS MODELOS DE CLASSIFICAÇÃO UTILIZADOS

| **Modelo** | **Parâmetros Utilizados** |
|---|---|
| Logistic Regression | `max_iter=2000`, solver padrão |
| SVM | Kernel padrão (`rbf`), `C=1.0` |
| KNN | `n_neighbors=5`, `minkowski` |
| Decision Tree | Critério padrão (`gini`) |
| Random Forest | `n_estimators=100` |
| Gradient Boosting | `n_estimators=100`, `lr=0.1` |
| AdaBoost | `n_estimators=50`, `lr=1.0` |
| Naive Bayes | Configuração Gaussiana |

### D. Métricas de Avaliação e Validação

A avaliação baseou-se nas matrizes de confusão e nas métricas de desempenho derivadas dos Verdadeiros Positivos (VP), Verdadeiros Negativos (VN), Falsos Positivos (FP) e Falsos Negativos (FN).

**Acurácia**: Proporção de acertos totais.

$$Accuracy = \frac{VP + VN}{Total} \tag{2}$$

**Precisão**: Dentre as áreas classificadas como Alto Risco, a proporção real.

$$Precision = \frac{VP}{VP + FP} \tag{3}$$

**Revocação (Recall)**: Das comunidades perigosas, quantas o modelo capturou. Em segurança pública, minimizar os Falsos Negativos é prioritário, tornando o Recall a métrica mais crítica.

$$Recall = \frac{VP}{VP + FN} \tag{4}$$

**F1-score**: Média harmônica entre Precisão e Recall.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \tag{5}$$

Para assegurar a robustez, o treino foi avaliado via *K-Fold Cross-Validation* ($K = 5$). A acurácia final relatada é a média das iterações, garantindo generalização.

## III. RESULTADOS

A etapa de avaliação revelou um panorama consistente: a submissão do dataset aos métodos de classificação sem a aplicação prévia do PCA culminou em métricas sistemicamente superiores. Isso aponta que as transformações de redução de dimensionalidade eliminaram informações não lineares cruciais para o traçado das fronteiras de decisão dos algoritmos.

Tabela II
COMPARAÇÃO DE TODAS AS MÉTRICAS DOS CLASSIFICADORES NO CONJUNTO DE TESTE

| **Modelo** | **Sem Redução de Dimensionalidade (Sem PCA)** | | | | **Com Redução de Dimensionalidade (Com PCA)** | | | |
|---|---|---|---|---|---|---|---|---|
| | **Acurácia** | **Precisão** | **Recall** | **F1-score** | **Acurácia** | **Precisão** | **Recall** | **F1-score** |
| Logistic Regression | 0.8471 | 0.8710 | 0.8141 | 0.8416 | 0.8396 | 0.8497 | 0.8241 | 0.8367 |
| Gradient Boosting | 0.8471 | 0.8594 | 0.8291 | 0.8440 | 0.8246 | 0.8342 | 0.8090 | 0.8214 |
| Random Forest | 0.8446 | 0.8703 | 0.8090 | 0.8385 | 0.8170 | 0.8462 | 0.7739 | 0.8084 |
| KNN | 0.8396 | 0.8534 | 0.8191 | 0.8359 | 0.8271 | 0.8495 | 0.7940 | 0.8208 |
| SVM | 0.8371 | 0.8641 | 0.7990 | 0.8303 | 0.8396 | 0.8571 | 0.8141 | 0.8351 |
| AdaBoost | 0.8271 | 0.8186 | 0.8392 | 0.8288 | 0.8120 | 0.8039 | 0.8241 | 0.8139 |
| Naive Bayes | 0.7970 | 0.8352 | 0.7387 | 0.7840 | 0.7694 | 0.8204 | 0.6884 | 0.7486 |
| Decision Tree | 0.7644 | 0.7586 | 0.7739 | 0.7662 | 0.7519 | 0.7451 | 0.7638 | 0.7543 |

### *A. Validação Cruzada (Cross-Validation)*

As Tabelas III e IV ilustram a acurácia média e o desvio padrão obtidos. Os desvios padrões consistentes confirmam a estabilidade estrutural dos algoritmos ao longo dos particionamentos.

Tabela III
VALIDAÇÃO CRUZADA SEM PCA

| **Modelo** | **CV Accuracy** | **Desvio** |
|---|---|---|
| Gradient Boosting | 0.8370 | 0.0157 |
| SVM | 0.8357 | 0.0134 |
| Logistic Regression | 0.8332 | 0.0172 |
| Random Forest | 0.8320 | 0.0100 |
| AdaBoost | 0.8082 | 0.0152 |
| Naive Bayes | 0.8031 | 0.0158 |
| KNN | 0.7981 | 0.0154 |
| Decision Tree | 0.7473 | 0.0171 |

Tabela IV
VALIDAÇÃO CRUZADA COM PCA

| **Modelo** | **CV Accuracy** | **Desvio** |
|---|---|---|
| Logistic Regression | 0.8357 | 0.0201 |
| SVM | 0.8332 | 0.0169 |
| Gradient Boosting | 0.8157 | 0.0183 |
| Random Forest | 0.8069 | 0.0164 |
| KNN | 0.8038 | 0.0153 |
| AdaBoost | 0.7962 | 0.0122 |
| Naive Bayes | 0.7624 | 0.0185 |
| Decision Tree | 0.7367 | 0.0139 |

### *B. Análise Comparativa no Conjunto de Teste*

A Tabela II exibe a comparação de todas as métricas no conjunto de Teste. Observa-se que apenas a Regressão Logística conseguiu manter acurácias próximas a 84% após o PCA, enquanto os algoritmos baseados em árvores sofreram quedas notórias em suas capacidades preditivas.

Em contrapartida, no cenário Sem PCA, fica evidente o ganho massivo dos algoritmos baseados em árvores (*Gradient Boosting* e *Random Forest*), que consolidaram as taxas mais altas e equilibradas de Recall e F1-Score do experimento, empatando com o poder preditivo da Regressão Logística.

### *C. Análise Individual e Matrizes de Confusão*

Com os resultados consolidados, aprofundou-se a observação do comportamento preditivo de cada algoritmo treinado na base otimizada (Sem PCA).

***Modelos de Maior Destaque: Gradient Boosting e Logistic Regression***

Os modelos Gradient Boosting e Regressão Logística atingiram a maior acurácia do experimento (84,7%). A análise de suas matrizes de confusão permite compreender as nuances de como cada algoritmo lidou com os erros de predição.

A matriz da Regressão Logística (Tabela V) evidencia um comportamento altamente equilibrado. O modelo apresenta um excelente volume de acertos na identificação de comunidades seguras (176), mantendo os erros de classificação distribuídos de forma muito simétrica entre falsos positivos e falsos negativos.

Tabela V
MATRIZES DE CONFUSÃO DO MODELO REGRESSÃO LOGÍSTICA

| | | **Classe Predita** | | | |
|---|---|---|---|---|---|
| | | **Sem PCA** | | **Com PCA** | |
| | | Baixo Risco | Alto Risco | Baixo Risco | Alto Risco |
| **Real** | **Baixo Risco** | 176 | 24 | 171 | 29 |
| | **Alto Risco** | 37 | 162 | 35 | 164 |

Em contraste, a matriz do Gradient Boosting (Tabela VI) revela uma clara otimização voltada para a detecção da classe alvo (Alto Risco). Visualmente, nota-se uma expressiva redução na incidência de Falsos Negativos (áreas perigosas preditas incorretamente como seguras) para apenas 34 casos. Essa característica reflete-se no Recall superior de 82,9%. Considerando o rigoroso contexto de segurança pública, onde omitir uma zona de alto risco é severamente mais prejudicial do que investigar um alarme falso, o Gradient Boosting apresenta a melhor aplicabilidade prática.

***Support Vector Machine (SVM), Random Forest e KNN***

O Random Forest também alcançou um forte desempenho com 84,4% de acurácia global e 80,9% de Recall para a classe

Tabela VI
MATRIZES DE CONFUSÃO DO MODELO GRADIENT BOOSTING

| | | Classe Predita | | | |
|---|---|---|---|---|---|
| | | **Sem PCA** | | **Com PCA** | |
| | | Baixo Risco | Alto Risco | Baixo Risco | Alto Risco |
| **Real** | **Baixo Risco** | 173 | 27 | 168 | 32 |
| | **Alto Risco** | 34 | 165 | 38 | 161 |

1, configurando-se como uma excelente alternativa de *ensemble*. O SVM atingiu uma acurácia de 83,7%, mas a observação de sua matriz revela que ele prioriza a precisão da classe 1 (86,4%) em detrimento de seu recall (79,9%). Já o KNN demonstrou acurácia levemente superior ao SVM (83,9%), conseguindo equilibrar melhor a identificação de ambas as classes.

***Modelos com Menor Desempenho***

As matrizes da Decision Tree e do Naive Bayes confirmam as métricas mais baixas. A Decision Tree apresentou instabilidade e muitos falsos positivos. O modelo Naive Bayes, por sua vez, exibe um claro viés na matriz, com dificuldade expressiva em identificar corretamente as instâncias de Alto Risco (grande volume de Falsos Negativos e Recall de apenas 73,8%).

## IV. CONCLUSÃO

Este trabalho investigou o desempenho de diferentes algoritmos de aprendizado de máquina na previsão de risco de criminalidade violenta utilizando o conjunto de dados *Communities and Crime*. Ao lidar com as dezenas de características socioeconômicas, notou-se, através do comparativo rigoroso no conjunto de testes, que a aplicação de PCA não forneceu ganhos de performance. Tal fato indica que os padrões não lineares das *features* originais são essenciais para a delimitação da fronteira de decisão.

Considerando as métricas apuradas e a natureza do problema — onde falhar em identificar uma zona de perigo é altamente indesejável — recomenda-se a utilização do modelo Gradient Boosting ou da Regressão Logística (treinados sem PCA). Ambos estabilizaram na mais alta taxa de acurácia global (84,7%) no conjunto de teste. O Gradient Boosting destaca-se por possuir o F1-Score mais alto (0.844) e o maior Recall (0.829) ao classificar instâncias da classe alvo (Alto Risco). Em contrapartida, a Regressão Logística oferece o benefício de uma arquitetura matematicamente explicável, fator indispensável para a transparência na formulação de políticas públicas baseadas em dados.

## Referências


MCCLENDON, Lawrence; MEGHANATHAN, Natarajan. Using Machine Learning Algorithms to Analyze Crime Data. **Machine Learning and Applications**, 2015.

PEDREGOSA, F. *et al.* Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

REDMOND, Michael; BAVEJA, Alok. Data Mining of the Communities and Crime Dataset, 2002.

REPOSITORY, UCI Machine Learning. **Communities and Crime Data Set**. [*S. l.: s. n.*], 1995. Disponível em: https://archive.ics.uci.edu/ml/datasets/communities+and+crime.

SHAW, Clifford; MCKAY, Henry. Juvenile Delinquency and Urban Areas. University of Chicago Press, 1942.

UNITED NATIONS OFFICE ON DRUGS AND CRIME. **Global study on homicide 2019**. [*S. l.*]: United Nations, 2019.